

CLIP Zero-Shot、Prompt Engineering 与 Linear Probe 在 CIFAR-10 上的对比实验

2026 年 8 月 26 日

摘要

本实验主要比较 CLIP ViT-B/32 在 CIFAR-10 上的几种分类方式，包括直接使用类别名的 Zero-shot、Single Prompt、Prompt Ensemble，以及冻结 CLIP image encoder 后训练 Linear Probe。实验结果中，class-name Zero-shot 的准确率为 87.38%，最佳单 Prompt 为 89.03%，Prompt Ensemble 为 88.87%，Linear Probe 最终达到 93.76%。从结果来看，Prompt 的写法确实会影响 Zero-shot 分类，但提升幅度有限，而且不同类别对 Prompt 的敏感程度不一样。相比之下，Linear Probe 只训练一个很小的线性层就取得了更明显的提升，说明 CLIP 的视觉特征本身已经包含较强的类别判别信息。

1 实验目的

这次实验主要想回答下面几个问题：

1. CLIP ViT-B/32 在 CIFAR-10 上直接做 Zero-shot 分类时的水平如何；
2. 给类别名增加不同的自然语言模板后，准确率会发生多大变化；
3. Prompt Ensemble 能否减少对特定 Prompt 写法的依赖；
4. 若冻结 CLIP 的 image encoder，只训练一个线性分类器，效果和 Zero-shot 相比会怎么样；
5. 哪些类别对 Prompt 比较敏感。

2 实验环境与数据

2.1 数据集

实验使用 CIFAR-10 数据集。训练集包含 50,000 张图像，测试集包含 10,000 张图像，共 10 个类别：

airplane、automobile、bird、cat、deer、dog、frog、horse、ship、truck。

所有图像都使用 CLIP 自带的 `preprocess` 进行预处理，没有再额外添加 `normalization`。

2.2 模型

所有实验都使用同一个 OpenAI CLIP ViT-B/32 checkpoint。图像特征和文本特征的维度都是 512。为了保证不同方法之间能够直接比较，实验过程中没有更换 backbone、checkpoint 和图像预处理方式。

3 实验方法

3.1 Zero-shot Baseline

最基础的设置是直接使用类别名作为文本输入。例如 airplane 类就只输入 “airplane”，不添加其他描述。

对图像特征和文本特征分别进行 L_2 normalization，然后计算二者的 cosine similarity：

$$S = F_{\text{image}} F_{\text{text}}^\top. \quad (1)$$

最后取相似度最大的类别作为预测结果。

3.2 Single Prompt Engineering

在类别名前后增加一个固定模板，测试了下面 4 个 Prompt：

- a photo of a {}
- a blurry photo of a {}
- a close-up photo of a {}
- an image of a {}

3.3 Prompt Ensemble

Prompt Ensemble 对每个类别构造上面 4 个 Prompt。每个文本 embedding 先进行 L_2 normalization，再对 4 个 embedding 求平均，最后把平均后的向量再次 normalization：

$$\bar{t}_c = \frac{\frac{1}{K} \sum_{k=1}^K \hat{t}_{c,k}}{\left\| \frac{1}{K} \sum_{k=1}^K \hat{t}_{c,k} \right\|_2}, \quad K = 4. \quad (2)$$

这样做的目的不是为某一个类别单独挑最佳 Prompt，而是让结果不要过度依赖某一个固定写法。

3.4 Linear Probe

Linear Probe 中冻结 CLIP 的 image encoder，只使用提取出的 512 维归一化视觉特征训练一个线性分类器：

$$\text{Linear} : \mathbb{R}^{512} \rightarrow \mathbb{R}^{10}. \quad (3)$$

线性层的参数量为 $512 \times 10 + 10 = 5,130$ 。

训练设置如表 1 所示。

表 1: Linear Probe 训练设置

参数	设置
Optimizer	AdamW
Learning rate	1×10^{-3}
Weight decay	1×10^{-4}
Epochs	20
Batch size	256
Trainable parameters	5,130

4 实验结果

4.1 Zero-shot Baseline

只使用类别名时，测试集整体准确率为：87.38%。

各类别准确率如表 2 所示。

表 2: Zero-shot class-name baseline 类别准确率

类别	准确率	类别	准确率
airplane	81.30%	dog	85.20%
automobile	89.90%	frog	77.00%
bird	91.70%	horse	97.10%
cat	79.20%	ship	96.30%
deer	82.20%	truck	93.90%

可以看到，Zero-shot 的整体表现已经比较高，但是不同类别之间差异很明显。horse 和 ship 的准确率很高，而 frog、cat 和 airplane 相对较低。

4.2 Single Prompt 结果

不同 Prompt 的总体结果如表 3 所示。

表 3: Single Prompt Engineering 总体结果

设置	Accuracy	相对 baseline
class name	87.38%	–
a photo of a {}	88.83%	+1.45 pp
a blurry photo of a {}	87.86%	+0.48 pp
a close-up photo of a {}	86.93%	–0.45 pp
an image of a {}	89.03%	+1.65 pp

最佳整体单模板是 `an image of a {}`。这个结果也说明 Prompt 并不是越长、越具体就越好。例如 `a close-up photo of a {}` 的准确率反而比只使用类别名低。

4.3 Prompt Sensitivity

这里把某个类别在全部 Prompt 设置中的最高准确率与最低准确率之差定义为 prompt sensitivity range。

实验中最敏感类别是 frog，为 18.20 pp；最稳定的类别是 horse，为 1.60 pp。

两者差距比较大，说明 Prompt 对不同类别的影响确实不一样。

4.4 Prompt Ensemble 结果

Prompt Ensemble 的总体准确率为 88.87%。

4 个成员 Prompt 的总体平均准确率是 88.16%，标准差为 0.84 pp。Ensemble 相对成员平均提高了 0.71 pp，比最差成员高 1.94 pp，但仍然比最佳单 Prompt 低 0.16 pp。

从类别上看，Ensemble 在 9/10 个类别上超过了成员 Prompt 的平均表现。例如 frog 的 Ensemble 为 76.40%，比成员均值高 2.33 pp，比最差 Prompt 高 13.80 pp。因此我认为 Ensemble 的主要作用更像是提高稳定性，而不是保证得到最高准确率。

4.5 Linear Probe 结果

Linear Probe 训练结束时得到：

- Final train loss: 0.2288
- Final train accuracy: 93.55%
- Training time: 7.93 s

在测试集上的准确率为 93.76%。

它比 class-name Zero-shot 高 6.38 个百分点，比最佳单 Prompt 高 4.73 个百分点，比 Prompt Ensemble 高 4.89 个百分点。

4.6 总体对比

表 4 汇总了四种主要方法的结果。

表 4: 四种主要设置的总体结果

设置	Accuracy	可训练参数	Training Cost
Zero-shot, class name	87.38%	0	仅推理
Best overall single prompt	89.03%	0	仅推理
Prompt Ensemble	88.87%	0	仅推理
Linear Probe	93.76%	5,130	7.93 s + 特征提取




图 1: CIFAR-10 上四种方法的总体准确率比较

从总体结果看, Prompt Engineering 大概带来 1-2 个百分点以内的变化, 而 Linear Probe 的提升更加明显。

5 类别级结果分析

不同方法的类别准确率如表 5 所示。

表 5: 不同方法的类别准确率 (%)

Class	Zero-shot	Best overall prompt	Ensemble	Linear Probe
airplane	81.30	89.50	88.80	96.30
automobile	89.90	93.80	96.70	96.90
bird	91.70	87.50	88.10	89.80
cat	79.20	87.00	85.40	89.00
deer	82.20	78.90	79.60	91.90
dog	85.20	88.90	87.60	90.10
frog	77.00	75.40	76.40	95.40
horse	97.10	96.70	96.80	94.90
ship	96.30	95.70	96.70	96.40
truck	93.90	96.90	92.60	96.90

这里的“Best overall prompt”指总体准确率最高的统一模板 `an image of a {}`，不是对每个类别分别选择最佳 Prompt。




图 2: 不同方法的类别准确率比较

从 Zero-shot 到 Linear Probe，提升比较明显的类别有：

- frog: +18.40 pp;
- airplane: +15.00 pp;
- cat: +9.80 pp;
- deer: +9.70 pp。

相反，horse 和 bird 分别下降 2.20 pp 和 1.90 pp。

我觉得 frog 是比较有代表性的类别。它一方面是 Prompt sensitivity 最大的类别，另一方面 Linear Probe 又能把准确率从 77.00% 提升到 95.40%。这说明 CLIP 的视觉特征中其实已经

包含了较强的 frog 判别信息，Zero-shot 的限制更可能出现在文本类别表示与视觉特征的对齐方式上。

horse 的情况则相反。它在 class-name Zero-shot 下已经达到 97.10%，Linear Probe 反而没有继续提高，说明这个类别和 CLIP 的文本语义空间本身就比较匹配。

6 Confusion Matrix 分析

Zero-shot 和 Linear Probe 的混淆矩阵如图 3 所示。




图 3: Zero-shot 与 Linear Probe 的混淆矩阵

Zero-shot 中最大的单向混淆为 deer $\rightarrow$ horse: 125, Linear Probe 中最大的单向混淆为 dog $\rightarrow$ cat: 60。

从混淆矩阵可以看到, Linear Probe 确实减少了很多错误, 但一些外观或语义比较接近的动物类别之间还是会出现混淆。

7 结果讨论

7.1 Prompt Engineering 的作用

从整体结果看, Prompt Engineering 是有效的, 但增益没有特别大。最佳模板相对 baseline 提升了 1.65 pp, 同时也存在模板使准确率下降的情况。

因此, Prompt Engineering 更像是在调整文本表示与视觉特征之间的匹配方式。它没有改变 image encoder, 也没有真正增加新的视觉信息。

7.2 Prompt Ensemble 的作用

Prompt Ensemble 没有超过最佳单 Prompt, 不过它比较接近最佳结果, 并且比 4 个 Prompt 的平均表现更高。特别是在一些对 Prompt 比较敏感的类别上, 它能明显减少最差 Prompt 带来

的性能下降。

所以我认为 Ensemble 的意义主要是让结果更稳，而不是一定要把准确率做得更高。

7.3 Linear Probe 说明了什么

Linear Probe 只训练了 5,130 个参数，却能达到 93.76%。这个结果说明 CLIP 的冻结视觉特征已经具有很强的线性可分性。

Zero-shot 和 Linear Probe 之间有 6.38 pp 的差距，这说明“视觉特征本身是否有信息”和“文本类别向量能不能把这些信息直接利用起来”并不是一回事。对于 frog、airplane、cat、deer 这类提升比较大的类别，Zero-shot 的瓶颈更可能是对齐问题，而不是 image encoder 完全没有学到相关视觉信息。

8 结论

通过这次实验，可以得到以下结论：

1. CLIP ViT-B/32 在 CIFAR-10 上已经有较强的 Zero-shot 分类能力，只使用类别名就能达到 87.38%；
2. Prompt wording 会明显影响 Zero-shot 分类结果，而且不同类别的敏感程度不同；
3. Prompt 写得更长、更具体不一定更好，部分 Prompt 甚至会让性能下降；
4. Prompt Ensemble 的主要优势是降低对单个 Prompt 的依赖，让结果更加稳定；
5. 冻结 CLIP image encoder 后，训练一个线性分类器可以达到 93.76%，明显超过所有 Zero-shot Prompt 方法；
6. Zero-shot 和 Linear Probe 的差距说明 CLIP 的视觉特征中包含了比当前文本 Prompt 能直接利用的更多类别判别信息。

总体来说，这次实验让我比较直观地看到：Prompt Engineering 主要影响 CLIP 的图文对齐，而 Linear Probe 更能反映冻结视觉特征本身的分类能力。